



Objectivos

- Adquirir a noção de classificador linear
- Adquirir a noção de máquina de vectores de suporte



- Sumário:

- Máquinas de vetores de suporte
 - Introdução
 - Classificação com máquinas de vetores de suporte



Máquinas de vetores de suporte (SVM)

- Foram introduzidas nos anos 90 por Vladimir Vapnik (1936 -)
- Se deriva da *Teoria de Aprendizagem Estatística*
- Técnica com muito êxito desde a sua introdução
 - Resultados práticos na resolução de diferentes tipos de problemas
 - Fundamentos teóricos sólidos



Máquinas de vetores de suporte (SVM)


- Se enquadram na categoria dos classificadores lineares



Classificadores lineares

- Dado um conjunto de treino $(\vec{x}_1, y_1), (\vec{x}_2, y_2), \dots, (\vec{x}_l, y_l), \vec{x}_i \in R^n, y_i \in \{-1, 1\}$
- O objectivo é encontrar um hiperplano h , de dimensão $n - 1$, que separe os exemplos da classe -1 dos exemplos da classe +1

Classificadores lineares



- O hiperplano de decisão é definido pela equação
 - $\vec{w} \cdot \vec{x} + b = 0$ ou
 - $\sum_{i=1}^n w_i x_i + b = 0$




Classificadores lineares

- Processo de aprendizagem consiste em determinar o vector de pesos (\vec{w}) e o umbral (b)
- Existem vários algoritmos que permitem aprender classificadores lineares
 - *Perceptron*
 - Regressão linear
 - Regressão logística...


Classificadores lineares

- Para um conjunto de dados linearmente separável existem várias superfícies de decisão possíveis



Classificadores lineares

- E se o conjunto de dados não for linearmente separável?






Máquinas de vetores de suporte


- Constituem uma extensão dos modelos lineares
- Têm como princípios fundamentais
 - A definição de superfícies de decisão com margem máxima
 - O uso de funções kernel
 - Permite construir *superfícies de decisão não lineares* usando *algoritmos lineares*

Hiperplano com margem máxima




- Existem diferentes hiperplanos de separação
- É possível definir algum critério de qualidade?

Hiperplano com margem máxima



- Relacionado com o conceito de margem
- O hiperplano que classifica melhor os dados é o correspondente à maior margem

Hiperplano com margem máxima



- Os vectores de dados mais próximos do hiperplano se denominam vectores de suporte
- Definem de forma única o hiperplano de separação
 - Todos os outros vectores são irrelevantes



Hiperplano com margem máxima

- A busca do hiperplano de margem máxima corresponde a um problema de otimização quadrática (Quadratic Programming, QP)
 - Se trata de encontrar os parâmetros que otimizam a uma equação de segundo grau, sujeita a uma série de restrições lineares sobre os referidos parâmetros
- A sua solução é dada na forma
 - $h(\vec{x}) : \vec{w} \cdot \vec{x} + b = \sum_{i=1}^l \alpha_i y_i (\vec{x}_i \cdot \vec{x}) + b$
 - $\alpha_i > 0$, se \vec{x}_i é um vector de suporte
 - $\alpha_i = 0$, se \vec{x}_i não é um vector de suporte




Dados não separáveis linearmente

- Nestes casos se aplica uma transformação não linear de forma a realizar a optimização num espaço em que os dados são linearmente separáveis
- Designado *espaço de características*

Dados não separáveis linearmente

Espaço de entrada

Espaço de características





Inconvenientes potenciais

- Difícil definir uma função de transformação adequada a cada problema
- Custo computacional da conversão dos vectores do espaço de entrada para o espaço de características
- Custo computacional do cálculo de produtos escalares no espaço de características



Funções kernel

- Permitem definir a função de transformação de forma implícita (não é necessário calculá-la para todos os vectores de dados)
- Permite calcular os produtos escalares no espaço de características aplicando a função sobre os vectores no espaço de entrada




Funções kernel

- Exemplos de funções kernel
 - Kernel linear: $K(\vec{x}, \vec{y}) = \vec{x} \cdot \vec{y}$
 - Kernel polinómico: $K(\vec{x}, \vec{y}) = (\vec{x} \cdot \vec{y} + r)^n$
 - Funções de base radial: $K(\vec{x}, \vec{y}) = e^{-\frac{\|\vec{x} - \vec{y}\|^2}{2\sigma}}$

Margem suave

- Quando a separabilidade linear não é possível (no *espaço de entradas* nem no *de características*) se relaxa o problema admitindo certa grau de erro no hiperplano óptimo
 - A quantidade de erro admitida é controlada por um parâmetro → parâmetro de penalização (C)
 - Valor de C é definido pelo usuário em cada problema





Exemplo 1

- Considere os seguintes exemplos de treino para um problema com duas classes:
 - Classe 1: (1, 1), (1, 2), (3, 2)
 - Classe 2: (-1, -1), (1, 0), (0, 1)
- Represente os seis pontos, construa a superfície de separação obtida através de SVM e mostre os vectores de suporte
- Conhecendo que a equação de uma recta é dada por $w \cdot x + b = 0$, trate de escrever a equação do hiperplano obtido na alínea anterior



Exemplo 2

- Considere o seguinte conjunto de treino formado por pontos com uma dimensão
 - Classe 1: -5, 5
 - Classe 2: -2, 1
- Represente graficamente os pontos. São separáveis linearmente?
- Considere a transformação $f : \mathbb{R} \rightarrow \mathbb{R}^2$, $f(x) = (x, x^2)$. Transforme os dados e represente-os no novo espaço
- Qual é o hiperplano de separação óptimo no espaço transformado? Corresponde a uma superfície de separação não linear no espaço original?



Tarefa

- Leitura da semana
 - Hsu, C. W., Chang, C. C. e Lin, C. J., “A Practical Guide to Support Vector Classification”



Bibliografia

- Witten, pg. 124 – 131, 223 – 227